Trabajo 2: pipeline batch y streaming en AWS

Universidad	Universidad EAFIT
Programa	Maestría en Ciencias de los Datos y Analítica
Curso	Almacenamiento y Procesamiento de Grandes Datos, 2026
Profesor	Edwin Montoya (emontoya@eafit.edu.co)
Valor	20% entrega del trabajo2, 10% sustentación oral vía Ms Teams
Modalidad	Equipos de 3 personas, conformados por los estudiantes. Los equipos de 4 son una excepción
Fecha de entrega	Viernes 6 de noviembre de 2026, hasta las 5 pm. Sustentaciones: 6 y 9 de noviembre de 2026.
Forma de entrega	Entrega por buzón (Asignaciones) de Eafit Interactiva.

1. Objetivo

El trabajo tiene dos partes, que se presentan en un video. La parte A es un pipeline batch con Apache Spark en AWS Glue, coordinado con AWS Step Functions y Amazon EventBridge Scheduler. La parte B es un flujo de streaming con Amazon Kinesis Data Streams, Amazon DynamoDB y Amazon S3, con una aplicación que calcula valores por ventanas de tiempo.

2. Condiciones

- **Datos de la parte A:** al menos 5.000.000 de registros, relacionados con un proyecto integrador (en adelante, el proyecto), en formato JSON o CSV, y un segundo conjunto de datos con el que se puedan unir. Si el primero tiene menos registros, el equipo lo aumenta hasta alcanzar ese mínimo.
- **Datos de la parte B:** ficticios o de un proyecto integrador, con una categoría y un campo numérico por evento.
- **Condiciones eliminatorias:** el trabajo debe cumplir las de la sección 7.

3. Parte A: pipeline batch

Construir en AWS Step Functions una máquina de estados, iniciada por un horario, con estos elementos:

1. **Horario.** Un horario de Amazon EventBridge Scheduler inicia la máquina de estados.
2. **Trabajo de Glue inicial.** Un trabajo de AWS Glue, con un script de PySpark escrito por el equipo, lee datos en JSON o CSV desde Amazon S3, los limpia (corrige o descarta los registros no válidos, por ejemplo duplicados o valores vacíos), los une (join) con otro conjunto de datos por una columna en común y escribe el resultado en S3 en formato Parquet, particionado por una columna que el equipo elija y justifique en el video.
3. **Dos ramas en paralelo.** Cuando el trabajo de Glue inicial termina con éxito, la máquina ejecuta a la vez dos ramas, sin intervención manual. Cada rama es un trabajo de Glue que lee los datos transformados, calcula una agrupación (un resumen calculado por grupos de registros) que responda una pregunta de analítica del proyecto, distinta de la de la otra rama, y la escribe en S3 en formato Parquet.
4. **Consulta.** Consultar el contenido de las dos agrupaciones, con Amazon Athena o con un notebook de Python, y mostrar en el video que responden la pregunta de analítica que el equipo formuló para cada una.

4. Parte B: streaming

Construir un flujo de streaming con Amazon Kinesis Data Streams que cumpla lo siguiente. El equipo elige e implementa las demás piezas que necesite.

1. **Productor.** Escribir un programa que publique eventos en un stream de Kinesis Data Streams de forma continua durante al menos 5 minutos. El productor repite a propósito algunos eventos y envía otros inválidos, por ejemplo con un campo faltante o con un valor numérico fuera de un rango que el equipo define.
2. **Ventanas.** Crear una aplicación que lea el stream y calcule, por ventanas de un minuto, el conteo de eventos y el promedio de un campo, por categoría. Un evento es repetido cuando coincide con uno ya recibido, y el equipo define cómo reconocerlo, por ejemplo con un identificador; un evento repetido no se cuenta dos veces. Se sugiere hacerla con Amazon Managed Service for Apache Flink (el servicio de AWS que ejecuta aplicaciones de Apache Flink, un motor de procesamiento de flujos de datos); también puede hacerse con AWS Lambda o con otra herramienta que el equipo elija.
3. **Eventos inválidos.** Apartar los eventos inválidos y guardar, con cada uno, el motivo por el que se descartó.
4. **Resultados.** Guardar en Amazon DynamoDB el resultado de cada ventana, y consultar la tabla para responder una pregunta del proyecto.
5. **Eventos crudos.** Crear un segundo consumidor del mismo stream (un programa que lee los eventos del stream) que guarde en Amazon S3 todos los eventos tal como llegan.
6. **Conteos.** Mostrar que los conteos cuadran: el número de eventos publicados es igual a la suma de los únicos procesados, los repetidos descartados y los inválidos descartados.

5. Video

- Publicado en YouTube.
- Contenido de la parte A: los datos de partida y su cantidad de registros; la máquina de estados con el trabajo inicial y las dos ramas en paralelo; una ejecución iniciada por el horario y terminada con éxito; el script del trabajo inicial; los datos transformados en Parquet en S3, con su columna de partición y por qué se eligió; las dos agrupaciones en Parquet; la consulta del contenido de cada agrupación y la pregunta de analítica que responde cada una.
- Contenido común: la consola de AWS CloudFormation sin ningún stack en la región de trabajo.
- Contenido de la parte B: el stream de Kinesis; el productor publicando; la aplicación que calcula las ventanas; los resultados en DynamoDB y la consulta que responde la pregunta; los eventos inválidos con su motivo; los eventos crudos en S3; y los conteos de publicados, procesados, repetidos e inválidos.
- Las tablas y las consolas deben verse con claridad en pantalla.
- No deben mostrarse credenciales de AWS ni datos sensibles del proyecto.

6. Informe y github

Cada proyecto deberá entregar un informe del trabajo 2 (markdown), que permita al profesor o a un tercero, realizar la reproducibilidad de su proyecto (mirar la estructura de los laboratorios que se entregan en clase). Este informe más el repositorio github deberá ser entregado por Asignaciones la fecha límite de entrega.

7. Condiciones eliminatorias

El incumplimiento de cualquiera de las siguientes condiciones implica una calificación de **0** en el trabajo, sin importar la calidad del resto.

1. **Recursos creados manualmente.** Los recursos deben crearse manualmente en la consola de AWS, sin infraestructura como código (Serverless Framework, CloudFormation, Terraform u otras), con el propósito de que los estudiantes se familiaricen con la nube y con su consola. La evidencia es la consola de AWS CloudFormation sin ningún stack en la región de trabajo, mostrada en el video. Si la cuenta conserva stacks de los laboratorios, deben eliminarse antes de grabar.
2. **Duración.** El video dura máximo **12 minutos**.
3. **Participación de todos los integrantes.** Todos los integrantes del equipo, es decir, los que figuran en el correo de entrega, hablan en el video y se ve su rostro mientras hablan.
4. **Entrega a tiempo y completa.** El correo se envía hasta las 6:00 pm del miércoles 4 de noviembre de 2026. Una entrega tardía tiene calificación de 0.
5. **Declaración explicita de eso de IA.** La IA no esta prohibida en el desarrollo de este proyecto 2, pero cada equipo deberá declarar explicitamente en que partes uso IA, y deberá declarar EXPLICITAMENTE que partes del proyecto 2 fue generada por IA: código, informes, textos, conclusiones, etc. Lo importante, es que cada miembro del equipo apropie y responda por todas las acciones de la IA y demuestre apropiación conceptual y aplicada de lo que genera la IA en el contexto del proyecto 2 y de la materia.

8. Criterios de evaluación

Se aplican a los trabajos que cumplen las condiciones eliminatorias de la sección 7.

Bloque	Criterio	Puntos
Parte A	Datos de partida: al menos 5.000.000 de registros relacionados con un proyecto integrador, reales o aumentados	3
	Horario de EventBridge Scheduler que inicia la máquina de estados, con una ejecución iniciada por el horario	5
	Trabajo de Glue inicial: script de PySpark escrito por el equipo y ejecutado con éxito, que lee datos en JSON o CSV desde S3	6
	Limpieza: el script corrige o descarta registros no válidos	4
	Unión (join) con otro conjunto de datos por una columna en común	4
	Datos transformados en Parquet, particionados por una columna justificada en el video	5
	Máquina de estados: las dos ramas se inician automáticamente, en paralelo, cuando el trabajo de Glue inicial termina con éxito, y la ejecución termina con éxito	5
	Primera rama: trabajo de Glue que escribe en Parquet una agrupación que responde una pregunta de analítica del proyecto	4
	Segunda rama: trabajo de Glue que escribe en Parquet una agrupación que responde una pregunta de analítica del proyecto, distinta de la primera	4
	Consulta del contenido de la primera agrupación, con Athena o con un notebook de Python, que muestra la respuesta a su pregunta de analítica	4
	Consulta del contenido de la segunda agrupación, con Athena o con un notebook de Python, que muestra la respuesta a su pregunta de analítica	4

Parte B	Stream de Kinesis Data Streams y productor que publica de forma continua durante al menos 5 minutos	6
	Eventos repetidos e inválidos enviados a propósito por el productor	3
	Aplicación que calcula, por ventanas de un minuto, el conteo y el promedio de un campo por categoría	8
	Los eventos repetidos no se cuentan dos veces	4
	Eventos inválidos apartados con su motivo	3
	Resultado de cada ventana guardado en DynamoDB	3
	Consulta a DynamoDB que responde una pregunta del proyecto	3
	Segundo consumidor que guarda en S3 los eventos crudos	4
	Conteos que cuadran: publicados igual a únicos procesados más repetidos descartados más inválidos descartados	3
Video	Exposición de la parte A: explicación clara del procedimiento y de los resultados	5
	Exposición de la parte B: explicación clara del flujo y de los resultados	5
	Legibilidad: tablas y consolas visibles con claridad en pantalla	5
Total		**100**

9. Sustentación Oral vía Ms Teams

Además de la entrega del trabajo 2, se seleccionará un miembro del equipo de forma aleatoria, el cual se deberá conectar por Ms Teams el día y la hora programada. De acuerdo al desempeño y apropiación de las respuestas dadas al profesor, todos los miembros del equipo tendrán la misma nota en este 10%. Se enviará agenda previamente. En caso extremo que se evidencie una desconexión alta del estudiante en el desarrollo del proyecto 2, se llamará a todo el equipo y se puede realizar penalización tambien en la entrega del trabajo. Las sustentaciones se programarán para el viernes 6 de nov durante el día, y el lunes 9 de nov despues de las 5pm.